

НАУЧНО-ИССЛЕДОВАТЕЛЬСКАЯ РАБОТА

EraSeMap: единый fail-closed алгоритм проверяемого удаления данных и влияния в модели

Доказательный аудит удаления биометрических данных

Автор _____

Организация _____

Научный
руководитель _____

2026

Аннотация

Команда удаления основной записи не гарантирует, что персональные данные перестали использоваться. Копии могут сохраняться в кэше, индексе, реплике, экспорте или backup; производные — в биометрическом шаблоне и векторе; влияние — в обученной модели. Более того, удалённый объект может появиться снова после restore, sync, rebuild или повторного развёртывания модели.

В работе представлен EraSeMap — один алгоритм из трёх стадий: **FIND** находит зарегистрированные и ограниченно скрытые пути; **ERASE** выбирает минимальный достаточный набор физических действий и machine unlearning; **PROVE** выполняет temporal replay и разрешает сертификат только после прохождения всех обязательных каналов. Алгоритм возвращает COMPLETE_WITHIN_ENVELOPE, INCOMPLETE или UNVERIFIED; отсутствие доказательств никогда не считается успехом.

В frozen transfer на 60 случаях EraSeMap дал 0 ложных COMPLETE против 5 у полного typed-аудита и 45 у native service status. Активный поиск bounded recovery-графа потребовал 7 проб против 13 у frozen random и 49 у exhaustive; greedy получил те же 7. В 20 парных опытах с реальными локальными процессами targeted plan был геометрически в 17,64 раза быстрее rebuild-all и записал на 94,62% меньше байтов. Temporal проверка обнаружила 30/30 латентных рисков и после controls дала 0/30 возвратов. Exact solvers совпали с exhaustive oracles в 3072/3072 и 16 384/16 384 конфигурациях. Быстрые unlearning-кандидаты на Qwen2.5-1.5B не прошли все frozen gates, поэтому exact retraining сохранён как безопасный fallback. Результаты относятся к зарегистрированным topology и transition envelopes; production FaceID/eGov и независимый hidden challenge не заявляются.

Ключевые слова: проверяемое удаление, machine unlearning, data lineage, temporal replay, биометрия, fail-closed, сертификат удаления.

1. Введение

Право на удаление и внутренние политики организаций требуют устранить данные одного человека. На практике одно событие порождает цепочку артефактов: исходную запись, нормализованный профиль, биометрический template, поисковый vector, cache, журнал, export, backup и параметры модели. Каждый компонент может вернуть успешную локальную квитанцию, хотя система в целом продолжает использовать человека.

Существующие направления решают части задачи. Data lineage описывает происхождение данных [9]. Machine unlearning уменьшает влияние обучающих примеров [1, 2], а verification-of-unlearning оценивает доказательность результата [3–8]. Политики удаления и патенты рассматривают lineage, backup и receipts [10–12, 16, 18]. Однако локальное доказательство одной части нельзя автоматически перенести на физические производные, модель и будущую регенерацию одновременно.

Исследовательский вопрос работы:

Как выдать один проверяемый subject-level вердикт удаления, который одновременно учитывает физические копии, производные, влияние в модели и зарегистрированные будущие пути восстановления?

Вклад работы:

1. единый трёхстадийный fail-closed алгоритм FIND–ERASE–PROVE;
2. формальная типизированная модель физического, производного и model-channel evidence;
3. exact minimum-cost selection с контрпримером при невозможности удаления;
4. temporal replay, запрещающий сертификат при возможной регенерации;
5. обязательное сравнение machine unlearning с exact retraining и сохранение отрицательных результатов;
6. воспроизводимая многоуровневая оценка на bounded graphs, реальных локальных процессах, stock services, face data и открытой модели Qwen2.5-1.5B.

2. Предшествующие работы и граница новизны



Рисунок 1. Один алгоритм EraSeMap: FIND, ERASE и PROVE. Составлено автором по протоколу EraSeMap.

EraSeMap не заявляет изобретение lineage graphs, set cover, active testing, temporal model checking, machine unlearning или цифровой подписи. Новизна формулируется уже и проверяемое: это композиция всех обязательств в одном subject-level decision rule, где ни одна локальная квитанция не может самостоятельно создать положительный verdict.

В отличие от обычного lineage-аудита, важен не только тип узла, но и пригодный путь от субъекта к активному артефакту. В отличие от model-only unlearning, удаление влияния в модели не закрывает backup, cache или vector index. В отличие от snapshot testing, текущая пустота не доказывает, что restore не вернёт объект. В отличие от универсального обещания, COMPLETE_WITHIN_ENVELOPE явно ограничивает гарантию зарегистрированной системой.

3. Модель системы

3.1 Типизированный граф

Пусть система представлена графом

$$G = (V, E, \tau, s),$$

где V — артефакты и сервисы, E — операции происхождения или восстановления, τ — типы узлов и рёбер, s — subject binding. Для субъекта u множество пригодных остаточных путей обозначается $R_u(G)$. Путь считается активным, если его конечный артефакт может хранить, выдавать, распознавать или восстанавливать информацию о u .

Обязательные каналы C_u включают:

- physical: исходные и резервные физические артефакты;
- derivative: templates, embeddings, indexes и exports;
- model: влияние в обученной модели;
- privacy: заранее объявленные privacy-proxy проверки;
- utility: качество для retained subjects/tasks;
- temporal: отсутствие возврата после будущих операций;
- coverage: достаточность зарегистрированной instrumentation.

Каждый verifier возвращает PASS, FAIL или UNKNOWN.

3.2 Три вердикта

COMPLETE_WITHIN_ENVELOPE:

$R_u(G) = \emptyset$ и каждый обязательный канал PASS,
discovery evidence валиден, temporal replay безопасен.

INCOMPLETE:

существует конкретный активный или регенерируемый путь.

UNVERIFIED:

ни остаток, ни полное удаление нельзя доказать доступным evidence.

Трёхзначность не является интерфейсной деталью: она исключает превращение отсутствующего evidence в ложный успех.

4. Единый алгоритм EraSeMap

4.1 FIND

FIND сначала replay-проверяет зарегистрированный граф. Если карта может быть неполной, adapter выполняет безопасные синтетические пробы: разрешает определённые recovery-операции и наблюдает, какой тестовый субъект, где и когда появился. После каждой пробы остаются только графы, совместимые с trace. Стадия возвращает единственный граф, полный observable path class, OUT_OF_HYPOTHESIS или UNVERIFIED.

Пусть H — конечный version space графов, а $Obs(q, h)$ — trace эксперимента q на гипотезе h . После наблюдения o :

$$H' = \{h \in H : \text{Obs}(q, h) = o\}.$$

Exact one-step minimax выбирает допустимую пробу, минимизирующую размер худшего следующего класса с детерминированным tie-break. Это локальная гарантия, а не оптимальность всего adaptive tree.

4.2 ERASE

Пусть A — конечный каталог разрешённых действий, $c(a) \geq 0$ — стоимость, $\text{Apply}(G, B)$ — система после подмножества $B \subseteq A$. План допустим, если все действия разрешены и replay закрывает каждый активный path и обязательный channel. Выбирается

$$B^* = \arg \min_{a \in B} \sum c(a) \\ \text{subject to Feasible}(B) = \text{true}.$$

При равенстве используется стабильный lexicographic tie-break. Если полного permitted plan нет, выдаётся INCOMPLETE или UNVERIFIED, но не частичная квитанция.

Model branch находится внутри ERASE. Candidate unlearning сравнивается с exact retraining по forgetting, retained utility, privacy proxy, deletion-matched distance и recurrence after reload. Общий model pass равен конъюнкции frozen gates. Провал одного gate означает fallback к exact retraining либо незавершённый model channel.

4.3 PROVE

Пусть q_0 — состояние после ERASE, а δ — зарегистрированные будущие переходы. Требуется, чтобы ни одно достижимое состояние не содержало пригодный residual:

$$\text{Safe}(u) \iff \forall q \in \text{Reach}(q_0, \delta): \text{Residual}(u, q) = \text{false}.$$

Если replay находит recurrence witness, PROVE возвращает INCOMPLETE и кратчайший контрпример. Если transition coverage неизвестен, результат UNVERIFIED. Только безопасный replay разрешает certificate-ready status.

4.4 Общая формула

Пусть P — закрытие physical/model paths, D — валидное discovery evidence, T — temporal safety:

$$\text{COMPLETE_WITHIN_ENVELOPE} \iff P \wedge D \wedge T.$$

5. Формальные свойства

Lean-проект проверяет четыре условных свойства без sorryAx:

1. replayed completion исключает представленные residual paths при полноте topology и sound local verifiers;
2. exact finite selector выбирает feasible plan не дороже любого другого listed feasible plan;
3. observed transition coverage переносит snapshot absence на все reachable registered states;
4. exact temporal selector безопасен и минимален при явной feasibility-soundness obligation.

Отдельные checked counterexamples показывают, что скрытый residual возможен без topology coverage и что passed channel бессмыслен без soundness. Python implementation отдельно

сравнивается с exhaustive oracles; Lean не доказывает Python semantics, adapters или реальную полноту организации.

6. Реализация

Публичный Python entry point `run_erasemap` возвращает три stage results и общий verdict. Service adapters отделены от pure verifier, поэтому алгоритм не выполняет неразрешённые network или destructive calls. Evidence bundles связываются hashes и, где предусмотрено протоколом, Ed25519 signatures. CLI создаёт offline-verifiable showcase и отчёты.

Внутренние названия PCUG, GhostGraph, CDC, RSE и MSC используются только для трассировки evidence и formal namespaces. Они не образуют пять конкурирующих пользовательских алгоритмов.

7. Методика экспериментов

7.1 Основная метрика

Критический риск — false-complete rate:

$FCR = \text{false COMPLETE} / \text{фактически незавершённые случаи}$.

Дополнительные метрики: probes, action cost, wall time, bytes written, retained loss, recurrence, oracle mismatches, forgetting, utility и privacy advantage.

7.2 Evidence layers

1. Mechanism stress проверяет различие typed-node и channel-aware path semantics.
2. Stock-service transfer использует digest-pinned Keycloak, MLflow и Qdrant на 60 frozen cases.
3. Bounded hidden graphs сравнивают active minimax, greedy, random и exhaustive FIND.
4. Measured multi-service experiment сравнивает targeted ERASE и rebuild-all на real PostgreSQL, Redis, Qdrant, encrypted backup и ridge model.
5. Temporal lab проверяет delayed restore, sync, cache/index rebuild и coverage faults.
6. Face experiments проверяют bounded unlearning и retained-user privacy.
7. Qwen-TOFU проверяет adapter-level learned influence на реальной открытой 1.5B model.

Протоколы, seeds, gates и source hashes фиксировались до соответствующих confirmation runs. Failed results не удаляются и не переписываются.

8. Результаты

Проверка	EraSeMap	Baseline	Интерпретация
Stock-service false COMPLETE	0/60	typed 5/60; native 45/60	FIND/coverage предотвращает локальную квитанцию

Проверка	EraSeMap	Baseline	Интерпретация
Hidden-graph probe budget	7	greedy 7; random 13; exhaustive 49	выигрыш против random/exhaustive, ничья с greedy
Exact action conformance	3072/3072	exhaustive oracle	0 mismatches в bounded domain
Targeted execution time	5,67%	rebuild-all 100%	17,64× geometric speedup
Written bytes	5,38%	rebuild-all 100%	94,62% reduction
Temporal risk detection	30/30	snapshot 0/30	PROVE проверяет более сильный future claim
Post-control recurrence	0/30	no control 30/30	registered controls закрыли frozen risks
Exact temporal conformance	16 384/16 384	exhaustive oracle	0 mismatches в bounded domain

Все 20 paired real-process cases сохранили completion и retained data. Frozen transfer также дал 0 retained loss и 0 post-control recurrence.

8.1 Model channel

Bounded face experiments дали положительное project-authored evidence, включая preregistered sequential retained-user privacy gates. Однако это не certified privacy.

Qwen v1 проверил три seeds и завершился FAIL: candidate приблизился к exact по части метрик, но не выполнил одновременно forgetting и world-utility требования. Qwen v2 использовал author-disjoint development selection и пять untouched confirmation seeds; candidate был быстрее минимум в 30,48 раза и имел нулевую recurrence after reload, но overscrubbing и несколько exact-matching/utility gates провалились. Итоговый model verdict для fast candidates остаётся incomplete; exact adapter retraining является reference fallback. Это не ухудшает логику EraSeMap, а демонстрирует её отказоустойчивость.

9. Обсуждение

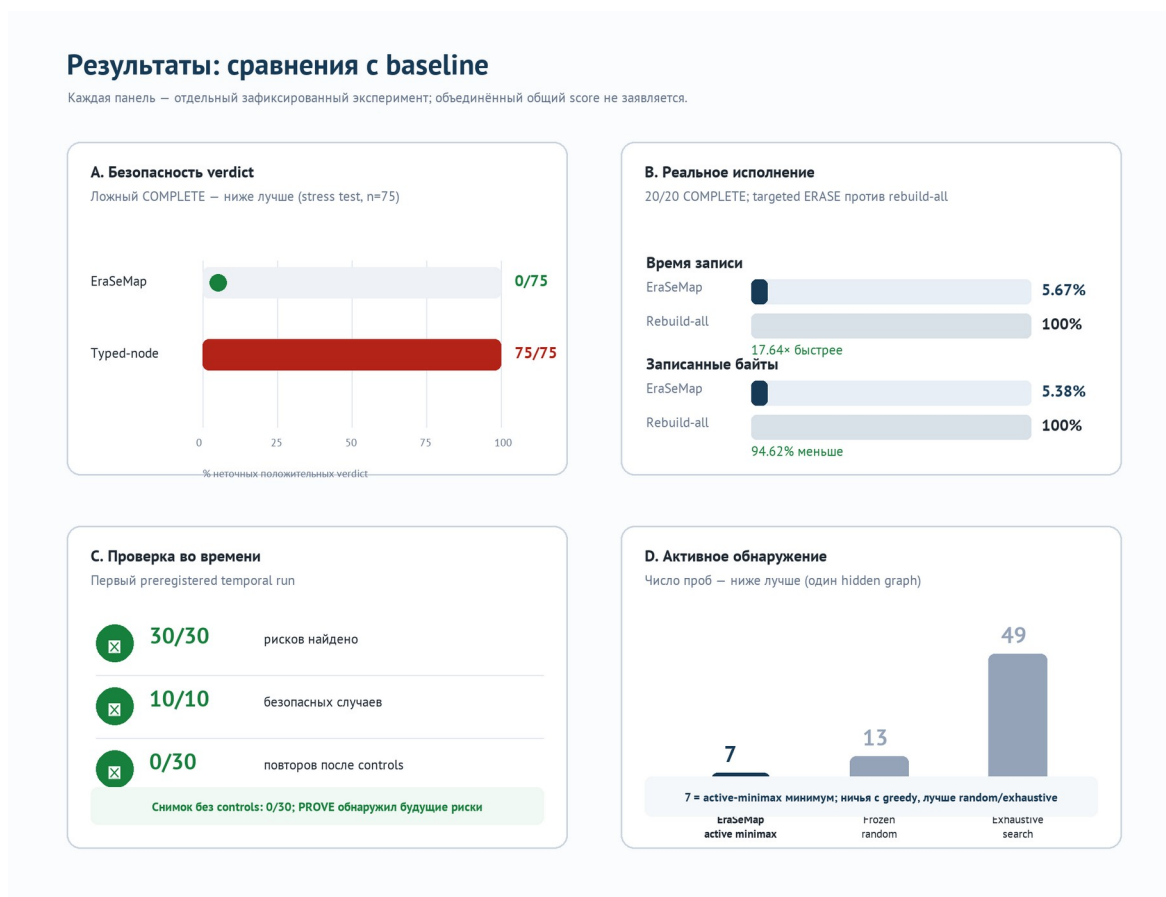


Рисунок 2. Четыре измеренных свойства единого алгоритма EraSeMap: безопасность, эффективность, временная проверка и активное обнаружение. Составлено автором по зафиксированным результатам.

Главный результат — не универсальное превосходство одного численного метода. EraSeMap связывает разные evidence types так, чтобы слабая локальная метрика не могла закрыть весь deletion request. Например, низкий membership score не доказывает удаление backup, а пустой snapshot не доказывает отсутствие future restore.

Active FIND уменьшает число диагностических проб, но strong greedy baseline получил ничью на frozen catalogue; эта ничья сохраняется. Targeted ERASE показывает большой systems saving против rebuild-all, однако на одной локальной машине. PROVE расширяет утверждение во времени, но только при transition coverage. Таким образом, каждая сильная цифра сопровождается собственной границей.

10. Ограничения и угрозы валидности

- Hidden graphs, mappings, faults и execution созданы проектом; accepted external run отсутствует.
- Stock services реальны, но subjects синтетические или публичные, а не customer records.
- Bounded catalogue не покрывает произвольную секретную инфраструктуру.

- Local verifier может быть неверным; signature защищает целостность, но не истинность измерения.
- Performance измерен на одной локальной конфигурации.
- Face privacy experiment не является certified privacy.
- Qwen experiments относятся к adapter influence, а не к удалению из pretraining Qwen.
- Production FaceID, eGov, KYC, bank или government deployment не проводился.

11. Этика и ответственное применение

Публичные демонстрации используют synthetic identities или открытые datasets. Active probes должны быть разрешены владельцем системы, изолированы и не затрагивать retained users. EraSeMap нельзя использовать для ложного compliance: score сертификата, UNKNOWN channels и instrumentation gaps должны оставаться видимыми.

12. Воспроизводимость

```
python -m venv .venv
.venv/bin/pip install -e '[dev,real]'
./scripts/reproduce_release.sh core
.venv/bin/erasemap showcase --repo-root . --output outputs/jury-showcase-v1
```

Release gate включает Ruff, strict мпы, pytest с coverage не ниже 90%, build, frozen evidence verifiers, oracle comparisons и Lean. External hidden challenge имеет отдельный blind handoff; текущий результат NOT_COLLECTED.

13. Заключение

EraSeMap превращает удаление данных из локальной команды в один проверяемый процесс. FIND находит зарегистрированные и bounded hidden paths; ERASE закрывает физические и model branches минимальным достаточным планом; PROVE проверяет future regeneration и разрешает scored certificate. Формальные свойства условны и явно ограничены assumptions; реальные отрицательные ML results сохранены. Такой дизайн лучше поддерживает честное решение в FaceID/eGov/KYC-подобных системах, но production и независимость остаются следующими этапами, а не готовыми claims.

Список литературы

- [1] Cao Y., Yang J. Towards Making Systems Forget with Machine Unlearning. IEEE S&P, 2015. DOI: 10.1109/SP.2015.35.
- [2] Bourtole L. et al. Machine Unlearning. IEEE S&P, 2021. arXiv:1912.03817.
- [3] Sommer D. M. et al. Towards Probabilistic Verification of Machine Unlearning. arXiv:2003.04247, 2020.
- [4] Weng J. et al. Proof of Unlearning: Definitions and Instantiation. arXiv:2210.11334, 2022.

- [5] Eisenhofer T. et al. Verifiable and Provably Secure Machine Unlearning. SaTML, 2025.
- [6] Chourasia R., Shah N. Forget Unlearning: Towards True Data-Deletion in Machine Learning. ICML, 2023.
- [7] Zhang B. et al. Verification of Machine Unlearning is Fragile. ICML, 2024.
- [8] Koloskova A. et al. Certified Unlearning for Neural Networks. ICML, 2025.
- [9] Lebo T., Sahoo S., McGuinness D., eds. PROV-O: The PROV Ontology. W3C Recommendation, 2013.
- [10] US20 220 414 070 A1. Tracking Data Lineage and Applying Data Removal to Enforce Data Removal Policies, 2022.
- [11] US11 120 156 B2. Privacy Preserving Data Deletion, 2021.
- [12] US12 456 052 B2. Systems and Methods for Facilitating Verifiability of ML Model Unlearning, 2025.
- [13] NIST SP 800-63A-4. Digital Identity Guidelines: Identity Proofing and Enrollment, 2025.
- [14] EraSeMap. Публичный репозиторий и evidence archive, v0.5.0, 2026:
<https://github.com/nazkari86-lab/erasemap>.
- [15] Chakraborty V. et al. Meaningful Data Erasure in the Presence of Dependencies. PVLDB 18(10), 2025.

Приложение А. Обозначения

Символ	Значение
$G=(V,E,\tau,s)$	зарегистрированный typed erasure graph
u	субъект одного deletion request
$R_u(G)$	активные остаточные пути субъекта
C_u	обязательные verifier channels
A	конечный каталог candidate actions
B^*	минимальный feasible action set
H	bounded version space recovery graphs
δ	зарегистрированные будущие переходы
FCR	false-complete rate

Приложение В. Claim-evidence map

Claim	Evidence	Граница
Replayed completion условно sound	Lean theorem и counterexamples	зависит от topology/verifier assumptions
Exact ERASE минимален	Lean + 3072/3072 oracle matches	finite registered catalogue
PROVE temporal-safe	Lean + 16 384/16 384 oracle matches	registered transition coverage
FIND уменьшает probe budget	7 vs 13 random vs 49 exhaustive	finite project-authored catalogue; greedy tie
Targeted ERASE дешевле rebuild-all	17,64× и -94,62% bytes	одна local system, synthetic identities
Fast Qwen unlearning успешен	не подтверждено: v1/v2 FAIL	exact retraining остаётся fallback
External hidden generalization	protocol ready	NOT_COLLECTED
Production FaceID/eGov	pilot protocol only	не установлено