

НАУЧНО-ИССЛЕДОВАТЕЛЬСКАЯ РАБОТА

EraSeMap: проверяемое удаление персональных данных из распределённых систем и моделей машинного обучения

Единый алгоритм FIND–ERASE–PROVE

Автор	Нұрланұлы Дулат, 9 «Б» класс
Организация	КГУ «Специализированный лицей-интернат „Білім-инновация“» Управления образования города Алматы
Направление	Направление II — математическое моделирование экономических и социальных процессов
Секция	Секция: информатика
Научный руководитель	Смағұл Ерзат Айдынұлы, учитель информатики

Алматы, 2026

Оглавление

Аннотация.....	3
Abstract.....	3
1. Введение.....	4
2. Предшествующие работы и граница новизны.....	4
3. Модель системы.....	5
4. Единый алгоритм EraSeMap.....	6
5. Формальные свойства.....	7
6. Реализация.....	7
7. Методика экспериментов.....	8
8. Результаты.....	8
9. Обсуждение.....	9
10. Ограничения и угрозы валидности.....	10
11. Этика и ответственное применение.....	10
12. Воспроизводимость.....	10
13. Заключение.....	11
Список литературы.....	11
Приложения.....	12

Аннотация

Команда удаления основной записи не гарантирует, что персональные данные перестали использоваться. Копии могут сохраняться в кэше, индексе, реплике, экспорте или резервной копии; производные — в биометрическом шаблоне и векторе; влияние — в обученной модели. Более того, удалённый объект может появиться снова после восстановления, синхронизации, пересборки или повторного развёртывания модели.

Я разработал и проверил EraSeMap — один алгоритм из трёх стадий: **FIND** находит известные и ограниченно неочевидные пути; **ERASE** выбирает минимальный достаточный набор физических действий и удаление влияния из модели (machine unlearning); **PROVE** повторяет будущие операции и разрешает сертификат только после прохождения всех обязательных проверок. Алгоритм возвращает COMPLETE_WITHIN_ENVELOPE, INCOMPLETE или UNVERIFIED; отсутствие доказательств никогда не считается успехом.

В заранее зафиксированной проверке переноса на 60 случаях EraSeMap дал 0 ложных COMPLETE против 5 у полного аудита узлов и 45 у обычного статуса сервиса. Активный поиск ограниченного графа восстановления потребовал 7 проб против 13 у случайной стратегии и 49 у полного перебора; жадная стратегия получила те же 7. В 20 парных опытах с реальными локальными процессами выбранный план был в среднем в 17,64 раза быстрее полной пересборки и записал на 94,62% меньше байтов. Временная проверка обнаружила 30/30 скрытых рисков и после контрольных действий дала 0/30 возвратов. Точные решатели совпали с полным перебором в 3072/3072 и 16 384/16 384 конфигурациях. Быстрые методы удаления влияния из Qwen2.5-1.5B не прошли все заранее заданные пороги, поэтому полное переобучение с нуля оставлено безопасным запасным вариантом. Результаты относятся к зарегистрированной топологии и описанным переходам; внедрение в FaceID/eGov и независимая скрытая проверка не заявляются.

Ключевые слова: проверяемое удаление, удаление влияния из модели, происхождение данных, временная проверка, биометрия, отказобезопасность, сертификат удаления.

Abstract

Deleting a primary record does not prove that personal data can no longer be used. Copies may remain in caches, indexes, replicas, exports, or backups; derivatives may remain as biometric templates and vectors; learned influence may remain in a trained model. A deleted object may also reappear after restoration, synchronization, rebuilding, or model redeployment.

I developed and tested EraSeMap as one algorithm with three stages. **FIND** locates known and bounded, non-obvious paths. **ERASE** selects a minimum sufficient set of physical actions and removes learned influence from the model (machine unlearning). **PROVE** repeats future operations and permits a certificate only after every required check passes. The algorithm returns COMPLETE_WITHIN_ENVELOPE, INCOMPLETE, or UNVERIFIED; missing evidence is never treated as success.

In a pre-registered 60-case transfer, EraSeMap produced 0 false COMPLETE decisions versus 5 for a full node audit and 45 for the service's ordinary status. Active recovery-graph search used 7 probes versus 13 for random testing and 49 for exhaustive testing. In 20 paired real-process trials, the selected plan was 17.64 times faster and wrote 94.62% fewer bytes than rebuild-all. Temporal verification detected 30/30 latent risks and produced 0/30 post-control recurrences. Exact solvers matched exhaustive oracles in 3,072/3,072 and 16,384/16,384 configurations. Fast unlearning candidates on Qwen2.5-1.5B failed all required thresholds together, so full retraining from scratch remains the safe fallback. Results are limited to registered topology and listed transitions; production deployment and an independent hidden result are not claimed.

Keywords: verifiable erasure, machine unlearning, data lineage, temporal replay, biometrics, fail-closed, deletion certificate.

1. Введение

Право на удаление и внутренние политики организаций требуют устранить данные одного человека. На практике одно событие порождает цепочку артефактов: исходную запись, нормализованный профиль, биометрический шаблон, поисковый вектор, кэш, журнал, экспорт, резервную копию и параметры модели. Каждый компонент может вернуть успешную локальную квитанцию, хотя система в целом продолжает использовать человека.

Существующие направления решают части задачи. Data lineage описывает происхождение данных [9]. Machine unlearning уменьшает влияние обучающих примеров [1, 2], а методы проверки unlearning оценивают результат [3–8]. Политики удаления и патенты рассматривают происхождение данных, резервные копии и квитанции [10–12, 16, 18]. Однако локальное доказательство одной части нельзя автоматически перенести на физические производные, модель и будущую регенерацию одновременно.

Вопрос, который я проверял:

Как выдать один проверяемый вердикт удаления для конкретного человека, который одновременно учитывает физические копии, производные, влияние в модели и зарегистрированные будущие пути восстановления?

Что сделано в работе:

1. один трёхстадийный алгоритм FIND–ERASE–PROVE, который не объявляет удаление завершённым без доказательств;
2. формальная типизированная модель физических копий, производных и влияния в модели;
3. точный выбор плана минимальной стоимости с контрпримером при невозможности удаления;
4. временная проверка, запрещающая сертификат при возможном возврате данных;
5. обязательное сравнение machine unlearning с полным переобучением и сохранение отрицательных результатов;
6. воспроизводимая оценка на ограниченных графах, реальных локальных процессах, готовых сервисах, данных лиц и открытой модели Qwen2.5-1.5B.

2. Предшествующие работы и граница новизны



Рисунок 1. Один алгоритм EraSeMap: FIND, ERASE и PROVE. Составлено автором по протоколу EraSeMap.

Я не заявляю, что изобрёл графы происхождения, задачу покрытия, активное тестирование, временную проверку моделей, machine unlearning или цифровую подпись. Результат работы уже: эти части соединены в одном правиле решения для конкретного человека, где ни одна локальная квитанция не может самостоятельно объявить удаление завершённым.

В отличие от обычного аудита происхождения данных, важен не только тип узла, но и пригодный путь от человека к активному артефакту. Удаление влияния в модели не очищает резервную копию, кэш или векторный индекс. Пустой снимок текущего состояния не доказывает, что восстановление не вернёт объект. Вердикт COMPLETE_WITHIN_ENVELOPE явно ограничивает гарантию зарегистрированной системой.

3. Модель системы

3.1 Типизированный граф

Пусть система представлена графом

$$G = (V, E, \tau, s),$$

где V — артефакты и сервисы, E — операции происхождения или восстановления, τ — типы узлов и рёбер, s — привязка к человеку. Для субъекта u множество пригодных остаточных путей обозначается $R_u(G)$. Путь считается активным, если его конечный артефакт может хранить, выдавать, распознавать или восстанавливать информацию о u .

Обязательные каналы C_u включают:

- physical: исходные и резервные физические артефакты;
- derivative: шаблоны, векторные представления, индексы и экспорты;
- model: влияние в обученной модели;
- privacy: заранее объявленные косвенные проверки приватности;

- **utility**: качество для оставшихся пользователей и задач;
- **temporal**: отсутствие возврата после будущих операций;
- **coverage**: достаточность зарегистрированных средств наблюдения.

Каждая локальная проверка возвращает PASS, FAIL или UNKNOWN.

3.2 Три вердикта

COMPLETE_WITHIN_ENVELOPE:

$R_u(G) = \emptyset$ и каждый обязательный канал PASS,
данные поиска действительны, временная проверка безопасна.

INCOMPLETE:

существует конкретный активный или регенерируемый путь.

UNVERIFIED:

доступных данных недостаточно, чтобы доказать остаток или полное удаление.

Три результата нужны не только для интерфейса: они не дают превратить отсутствие доказательств в ложный успех.

4. Единый алгоритм EraSeMap

4.1 FIND

FIND сначала повторно проверяет зарегистрированный граф. Если карта может быть неполной, адаптер выполняет безопасные синтетические пробы: разрешает определённые операции восстановления и наблюдает, какой тестовый субъект, где и когда появился. После каждой пробы остаются только графы, совместимые с наблюдением. Стадия возвращает единственный граф, полный наблюдаемый класс путей, OUT_OF_HYPOTHESIS или UNVERIFIED.

Пусть H — конечное множество возможных графов, а $Obs(q, h)$ — наблюдение эксперимента q на гипотезе h . После наблюдения o :

$$H' = \{h \in H : Obs(q, h) = o\}.$$

Точный одноступенчатый minimax выбирает допустимую пробу, которая уменьшает худший следующий класс гипотез; при равенстве используется фиксированное правило. Это гарантия для следующей пробы, а не обещание оптимальности всего дерева.

4.2 ERASE

Пусть A — конечный каталог разрешённых действий, $c(a) \geq 0$ — стоимость, $Apply(G, B)$ — система после подмножества $B \subseteq A$. План допустим, если все действия разрешены и повторная проверка закрывает каждый активный путь и обязательный канал. Выбирается

$$B^* = \arg \min_{a \in B} \sum c(a)$$

при условии $Feasible(B) = \text{true}$.

При равенстве используется стабильный лексикографический порядок. Если полного разрешённого плана нет, выдаётся INCOMPLETE или UNVERIFIED, но не частичная квитанция.

Ветка модели входит в ERASE. Быстрый метод сравнивается с полным переобучением по забыванию удалённых примеров, качеству для оставшихся пользователей, privacy-проху, расстоянию до переобученной модели и повторному появлению влияния после загрузки. Модель считается прошедшей только при одновременном выполнении всех заранее заданных порогов. Провал одного порога означает переход к полному переобучению или незавершённый модельный канал.

4.3 PROVE

Пусть q_0 — состояние после ERASE, а δ — зарегистрированные будущие переходы. Требуется, чтобы ни одно достижимое состояние не содержало пригодный остаток:

$$\text{Safe}(u) \iff \forall q \in \text{Reach}(q_0, \delta): \text{Residual}(u, q) = \text{false}.$$

Если повтор операций находит свидетельство возврата, PROVE возвращает INCOMPLETE и краткий контрпример. Если полнота переходов неизвестна, результат UNVERIFIED. Сертификат можно выдать только после успешной временной проверки.

4.4 Общая формула

Пусть P — закрытие физических и модельных путей, D — действительные данные поиска, T — безопасность во времени:

$$\text{COMPLETE_WITHIN_ENVELOPE} \iff P \wedge D \wedge T.$$

5. Формальные свойства

Lean-проект проверяет четыре условных свойства без sorryAx:

1. завершённая повторная проверка исключает представленные остаточные пути при полноте топологии и корректности локальных проверок;
2. точный конечный решатель выбирает допустимый план не дороже любого другого перечисленного плана;
3. наблюдаемые переходы позволяют распространить отсутствие данных на все достижимые зарегистрированные состояния;
4. точный временной решатель безопасен и минимален при явно указанном условии корректности.

Отдельные проверенные контрпримеры показывают, что без полной карты может остаться скрытый путь, а статус PASS не имеет смысла без корректной локальной проверки.

Реализация на Python отдельно сравнивается с полным перебором; Lean не доказывает семантику Python, адаптеры или реальную полноту инфраструктуры организации.

6. Реализация

Публичная функция Python `run_erasemap` возвращает результаты трёх шагов и общий вердикт. Адаптеры сервисов отделены от чистой проверяющей части, поэтому алгоритм не выполняет неразрешённые сетевые или разрушающие операции. Пакеты доказательств

связываются хешами и, где это предусмотрено протоколом, подписями Ed25519. Командная строка создаёт офлайн-демонстрацию и отчёты, которые можно проверить.

Названия PCUG, GhostGraph, CDC, RSE и MSC нужны только внутри отчётов и формальной части. Для пользователя это не пять разных алгоритмов, а внутренние обозначения отдельных проверок одного EraSeMap.

7. Как проводилась проверка

7.1 Основная метрика

Критический риск — доля ложных завершений (false-complete rate):

$FCR = \text{ложные COMPLETE} / \text{фактически незавершённые случаи}$.

Дополнительные метрики: число проб, стоимость действий, время выполнения, записанные байты, потеря данных остальных пользователей, возвраты, расхождения с полным перебором, забывание, качество и privacy advantage.

7.2 Уровни проверки

1. Тест механизмов проверяет разницу между аудитом только узлов и проверкой пригодного пути.
2. Перенос на готовые сервисы использует зафиксированные версии Keycloak, MLflow и Qdrant в 60 случаях.
3. На ограниченном наборе скрытых графов сравниваются активный поиск, жадная, случайная стратегии и полный перебор.
4. В опыте с несколькими сервисами сравниваются выбранный ERASE и полная пересборка на PostgreSQL, Redis, зашифрованной резервной копии и ridge-модели.
5. Временная лаборатория проверяет отложенное восстановление, синхронизацию, пересборку кэша и индекса, а также ошибки неполной регистрации.
6. Опыты с лицами проверяют ограниченное удаление влияния и качество для оставшихся пользователей.
7. Qwen-TOFU проверяет влияние обучающих примеров на реально доступной модели 1.5B.

Протоколы, начальные значения, пороги и хеши исходников фиксировались до подтверждающих запусков. Неудачные результаты сохранены и не переписывались.

8. Результаты

Проверка	EraSeMap	Baseline	Интерпретация
Ложный COMPLETE на сервисах	0/60	аудит узлов 5/60; обычный статус 45/60	проверяется путь, а не только ответ команды

Проверка	EraSeMap	Baseline	Интерпретация
Число проб для скрытого графа	7	жадная 7; случайная 13; полный перебор 49	выигрыш против случайной и полного перебора; с жадной — ничья
Совпадение решателя действий	3072/3072	полный перебор	расхождений в ограниченной задаче нет
Время выполнения плана	5,67%	полная пересборка 100%	план в 17,64 раза быстрее
Записанные байты	5,38%	полная пересборка 100%	на 94,62% меньше
Поиск временных рисков	30/30	снимок состояния 0/30	найлены будущие возвраты
Возврат после контроля	0/30	без контроля 30/30	проверенные действия закрыли эти риски
Совпадение временного решателя	16 384/16 384	полный перебор	расхождений в ограниченной задаче нет

Во всех 20 парных опытах локальные процессы завершились, а данные остальных пользователей сохранились. В проверке переноса также не было потери retained-данных и возвратов после контроля.

8.1 Проверка модели

В опытах с лицами получены положительные результаты на данных, подготовленных проектом, включая последовательную проверку качества для оставшихся пользователей. Это не сертифицированное доказательство конфиденциальности.

Qwen v1 проверил три начальных значения и завершился FAIL: кандидат приблизился к полному переобучению по части метрик, но одновременно не выполнил требования по забыванию и качеству для остальных задач. В Qwen v2 выбор параметров отделён от подтверждения пятью новыми начальными значениями; кандидат был минимум в 30,48 раза быстрее и не вернул влияние после загрузки, но чрезмерно затронул другие примеры и провалил несколько проверок совпадения и качества. Поэтому быстрый кандидат получил FAIL, а полное переобучение адаптера осталось запасным вариантом. Так и должна работать защитная проверка.

9. Обсуждение

Результаты: сравнения с baseline

Каждая панель — отдельный зафиксированный эксперимент; объединённый общий score не заявляется.




Рисунок 2. Четыре измеренных свойства единого алгоритма EraSeMap: безопасность, эффективность, временная проверка и активное обнаружение. Составлено автором по зафиксированным результатам.

Главный результат — не обещание превосходства над любым численным методом.

EraSeMap связывает разные виды свидетельств, поэтому слабая локальная метрика не закрывает весь запрос на удаление. Например, низкий показатель membership-атаки не доказывает удаление резервной копии, а пустой снимок не доказывает, что будущее восстановление невозможно.

Активный FIND уменьшает число диагностических проб, но жадная базовая стратегия дала такую же цифру на зафиксированном наборе; это не скрывается. Выбранный ERASE экономит время по сравнению с полной пересборкой, но измерение сделано на одной локальной машине. PROVE проверяет будущее только там, где переходы зарегистрированы. Поэтому у каждой цифры есть своя граница.

10. Ограничения и угрозы валидности

- Скрытые графы, соответствия, ошибки и запуск созданы проектом; внешнего принятого запуска нет.
- Сервисы настоящие, но субъекты синтетические или публичные, а не записи клиентов.
- Ограниченный список не покрывает произвольную секретную инфраструктуру.

- Локальный проверяющий код может содержать ошибку; подпись защищает файл от подмены, но не доказывает правильность самого измерения.
- Скорость измерения на одной локальной конфигурации.
- Опыт с приватностью лиц не является сертификацией приватности.
- Опыты Qwen относятся к влиянию адаптера, а не к удалению из исходного предобучения Qwen.
- Внедрение в FaceID, eGov, KYC, банк или государственную систему не проводилось.

11. Этика и ответственное применение

Публичные демонстрации используют синтетические личности или открытые наборы данных. Тестовые пробы нужно заранее согласовать с владельцем системы, проводить изолированно и не направлять на данные оставшихся пользователей. EraSeMap нельзя использовать для формального отчёта «для галочки»: в нём должны быть видны граница сертификата, неизвестные каналы и пробелы в регистрации.

12. Воспроизводимость

```
python -m venv .venv
.venv/bin/pip install -e '[dev,real]'
./scripts/reproduce_release.sh core
.venv/bin/erasemap showcase --repo-root . --output outputs/jury-showcase-v1
```

Проверка релиза включает Ruff, strict муру, pytest с покрытием не ниже 90%, сборку, проверяющие скрипты для зафиксированных данных, сравнение с полным перебором и Lean. Для внешней скрытой проверки подготовлен отдельный пакет; результат пока NOT_COLLECTED.

13. Заключение

EraSeMap превращает удаление данных из одной команды в последовательную проверку. FIND находит зарегистрированные и ограниченно скрытые пути; ERASE закрывает физические и модельные ветви самым дешёвым достаточным планом; PROVE проверяет возможность будущего восстановления и выдаёт сертификат только в оговорённых пределах. Формальные свойства зависят от явно указанных предположений, а отрицательные результаты по ML сохранены. Внедрение в FaceID/eGov-подобные системы и независимая проверка остаются следующими шагами, а не готовыми результатами.

Список литературы

- [1] Cao Y., Yang J. Towards Making Systems Forget with Machine Unlearning. IEEE S&P, 2015. DOI: 10.1109/SP.2015.35.
- [2] Bourtole L. et al. Machine Unlearning. IEEE S&P, 2021. arXiv:1912.03817.

- [3] Sommer D. M. et al. Towards Probabilistic Verification of Machine Unlearning. arXiv:2003.04247, 2020.
- [4] Weng J. et al. Proof of Unlearning: Definitions and Instantiation. arXiv:2210.11334, 2022.
- [5] Eisenhofer T. et al. Verifiable and Provably Secure Machine Unlearning. SaTML, 2025.
- [6] Chourasia R., Shah N. Forget Unlearning: Towards True Data-Deletion in Machine Learning. ICML, 2023.
- [7] Zhang B. et al. Verification of Machine Unlearning is Fragile. ICML, 2024.
- [8] Koloskova A. et al. Certified Unlearning for Neural Networks. ICML, 2025.
- [9] Lebo T., Sahoo S., McGuinness D., eds. PROV-O: The PROV Ontology. W3C Recommendation, 2013.
- [10] US20 220 414 070A1. Tracking Data Lineage and Applying Data Removal to Enforce Data Removal Policies, 2022.
- [11] US11 120 156B2. Privacy Preserving Data Deletion, 2021.
- [12] US12 456 052B2. Systems and Methods for Facilitating Verifiability of ML Model Unlearning, 2025.
- [13] NIST SP 800-63A-4. Digital Identity Guidelines: Identity Proofing and Enrollment, 2025.
- [14] EraSeMap. Публичный репозиторий и evidence archive, v0.5.0, 2026:
<https://github.com/nazkari86-lab/erasemap>.
- [15] Chakraborty V. et al. Meaningful Data Erasure in the Presence of Dependencies. PVLDB 18(10), 2025.

Приложение А. Обозначения

Символ	Значение
$G=(V,E,\tau,s)$	зарегистрированный типизированный граф удаления
u	человек, к которому относится запрос на удаление
$R_u(G)$	активные остаточные пути субъекта
C_u	обязательные каналы проверки
A	конечный каталог возможных действий
B^*	минимальный допустимый набор действий
H	ограниченное множество возможных графов восстановления
δ	зарегистрированные будущие переходы
FCR	доля ложных завершений

Приложение В. Связь утверждений и результатов

Утверждение	Результат	Граница
Повторная проверка условно корректна	теорема Leap и контрпримеры	зависит от полноты топологии и корректности проверок
ERASE выбирает минимальный план	Leap и 3072/3072 совпадений с полным перебором	конечный зарегистрированный каталог
PROVE безопасен во времени	Leap и 16 384/16 384 совпадений с полным перебором	только зарегистрированные переходы
FIND уменьшает число проб	7 против 13 у случайной стратегии и 49 у полного перебора	конечный набор проекта; с жадной стратегией ничья
Выбранный ERASE дешевле полной пересборки	ускорение 17,64× и на 94,62% меньше байтов	одна локальная система, синтетические личности
Быстрое удаление влияния из Qwen успешно	не подтверждено: v1/v2 FAIL	полное переобучение остаётся запасным вариантом
Перенос на независимый скрытый набор	протокол готов	NOT_COLLECTED
Внедрение в FaceID/eGov	есть только протокол пилота	не установлено